

Método de Calibración Contextual (MCC): Un protocolo de control en la capa de interacción para Grandes Modelos de Lenguaje

****Autor:**** IndioYori

****Afiliación:**** Investigación independiente / Comunidad CLACSO

****Versión del protocolo:**** MCC v1.0

****Tipo de documento:**** Artículo técnico – evidencia preliminar multi-modelo

****Fecha:**** Julio 2026

****Estado:**** Preprint – sujeto a revisión por pares

Resumen

Los Grandes Modelos de Lenguaje (LLMs) generan texto con alta fluidez y un formato de certeza retórica que no refleja proporcionalmente la solidez epistémica de sus afirmaciones. Este artículo presenta el ****Método de Calibración Contextual (MCC)****, un protocolo operativo de cuatro capas que interviene exclusivamente en la formulación de entradas y la evaluación estructurada de salidas, sin modificar pesos, arquitectura ni acceso interno al modelo. El MCC aborda tres propiedades estructurales no declaradas de la gramática computacional de generación: ****Certeza sin Sustancia****, ****Optimización Silenciosa**** y ****Sesgo de Contexto Implícito****. Se reporta evidencia empírica obtenida mediante pares de consultas genéricas y situadas aplicadas a cuatro modelos (DeepSeek, Grok, Qwen, ChatGPT) en dos dominios temáticos (detección de IA, mestizaje). Los resultados muestran un patrón consistente en las cuatro capas del protocolo: desplazamiento de marco semántico, bifurcación argumentativa, uniformidad de certeza retórica y transferencia de frameworks interpretativos. Se discuten implicaciones para la ingeniería de interacción humano-LLM, amenazas a la validez y un protocolo de replicación detallado. La contribución principal es operacionalizar el fenómeno de inaccesibilidad condicionada del conocimiento paramétrico en un protocolo aplicable por cualquier usuario, con criterios de evaluación explícitos y secuencia reproducible.

****Palabras clave:**** LLM, Transformer, calibración contextual, prompting estructurado, incertidumbre, evaluación en caja negra, interacción humano-IA, soberanía cognitiva.

1. Introducción

Los sistemas basados en arquitectura Transformer (Vaswani et al., 2017) han democratizado el acceso a capacidades de razonamiento, síntesis y generación textual. Sin embargo, su interfaz conversacional oculta propiedades computacionales que no están declaradas al usuario: el modelo produce texto con distribución de certeza retórica uniforme, converge hacia una única respuesta de máxima verosimilitud sin reportar alternativas descartadas, y asume un perfil de usuario por defecto derivado de la distribución estadística de sus datos de entrenamiento (Bender et al., 2021; Weidinger et al., 2021).

Estas propiedades no constituyen fallos de implementación. Son consecuencias directas del diseño: decodificación autoregresiva por máxima verosimilitud (Holtzman et al., 2020), ausencia de canal explícito de confianza epistémica, y compresión de conocimiento heterogéneo en pesos paramétricos accesibles de forma condicionada por la entrada (Petroni et al., 2019; Jiang et al., 2020). La literatura reciente ha documentado que los LLMs exhiben "conocimiento latente" que no se manifiesta bajo formulaciones genéricas (Liu et al., 2023; Press et al., 2022), pero rara vez se ha traducido este hallazgo en un protocolo operativo para usuarios finales.

El **Método de Calibración Contextual (MCC)** se propone como respuesta a esta brecha. No es una técnica de prompting heurístico ni una interpretación filosófica de la interacción humano-IA. Es un **protocolo de calibración** en la capa de interacción que permite al usuario detectar, medir y corregir las distorsiones producidas por la gramática de optimización del modelo, devolviendo control sobre la dirección, profundidad y calidad epistémica del diálogo. El MCC se enmarca en un creciente cuerpo de trabajo que busca intervenir la arquitectura Transformer desde la superficie lingüística (Zhao et al., 2021; Webson & Pavlick, 2022), pero se distingue por su enfoque en la **evaluación estructurada** y la **transferencia de capacidad** como criterios de éxito.

Este artículo presenta la especificación del protocolo MCC v1.0, la metodología empleada para su verificación empírica, los resultados obtenidos en un estudio comparativo multi-modelo, y un marco para replicación independiente. El objetivo es doble: (1) proporcionar a la comunidad académica un protocolo reproducible para calibrar la interacción humano-LLM, y (2) ofrecer a usuarios finales una herramienta práctica para

recuperar autonomía epistémica en sus diálogos con sistemas generativos.

2. Marco teórico

2.1 Mecanismos arquitectónicos relevantes para la interacción

La arquitectura Transformer se compone de múltiples capas de atención multi-cabeza y redes feed-forward que procesan secuencias de tokens de forma autoregresiva. Para los fines del MCC, tres mecanismos son particularmente relevantes:

****Espacio de embeddings.**** Los tokens de entrada se proyectan a vectores de alta dimensionalidad, y secuencias semánticamente relacionadas ocupan regiones vecinas en este espacio. Pequeñas variaciones en la secuencia de entrada pueden producir grandes desplazamientos en la representación vectorial (Liu et al., 2023; Ethayarajh, 2019), lo que hace que el modelo sea sensible a modificaciones aparentemente menores en la formulación de la consulta.

****Mecanismo de atención multi-cabeza.**** El modelo asigna pesos diferenciales a cada token del contexto en función de su relevancia para la posición actual. La estructura sintáctica de la entrada determina qué relaciones entre tokens reciben mayor peso (Vaswani et al., 2017), influyendo directamente en qué información del contexto se utiliza para la generación.

****Distribución de probabilidad de siguiente token.**** La generación autoregresiva selecciona cada token según una distribución softmax condicionada por la historia completa de entrada y salida (Holtzman et al., 2020). Esta distribución es sensible a la historia de generación desde el primer token, lo que implica que cambios tempranos en la consulta pueden afectar toda la trayectoria de salida.

2.2 Propiedades estructurales de la generación en LLMs

La generación autoregresiva en Transformers opera mediante la estimación secuencial de probabilidades condicionadas:

$$P(x_t \mid x_{<t}, \text{prompt}) = \text{softmax}(W \cdot h_t)$$

donde (h_t) es el estado oculto en el paso (t) , determinado por la atención multi-cabeza sobre la secuencia de entrada y los tokens generados previamente. Tres consecuencias relevantes para el MCC:

****Certeza sin Sustancia.**** El modelo no dispone de un canal separado para señalar confianza epistémica (Kadavath et al., 2022). El tono declarativo de *"sé esto con seguridad"* y el de *"estoy generando la secuencia más probable"* comparten el mismo formato de salida (Mielke et al., 2022). La calibración retórica y la calibración epistémica no están acopladas, lo que genera un problema de evaluación para usuarios sin formación técnica (Bender et al., 2021).

****Optimización Silenciosa.**** La función objetivo de decodificación selecciona una trayectoria de tokens que maximiza verosimilitud local (Holtzman et al., 2020). Alternativas válidas con probabilidad comparable se descartan sin registro (Press et al., 2022). El usuario recibe una respuesta, no un espacio de respuestas, lo que oculta la naturaleza contingente y probabilística de la generación (Weidinger et al., 2021).

****Sesgo de Contexto Implícito.**** Ante ausencia de contexto explícito, el modelo activa un perfil por defecto – estadísticamente angloparlante, urbano, con acceso a recursos – que no corresponde a la mayoría de usuarios reales (Bender et al., 2021; Crawford, 2021). El conocimiento paramétrico relevante para contextos situados permanece latente, no ausente (Petroni et al., 2019; Jiang et al., 2020). Este fenómeno, que el MCC denomina ****Olvido Estructural****, es central para la eficacia del protocolo.

2.3 Posicionamiento del MCC respecto al estado del arte

El MCC se distingue de técnicas de prompting convencionales (Zhao et al., 2021; Webson & Pavlick, 2022) en cuatro aspectos fundamentales:

1. ****Opera sobre propiedades estructurales****, no sobre contenido temático. No busca "mejor respuesta" en términos de calidad percibida, sino modificar el ****tipo de interacción****.
2. ****Incluye evaluación de salida**** como parte integral del protocolo, no solo formulación de entrada. La capa de verificación de certeza (`KNOWN_PROBE`) es un componente estructural, no opcional.
3. ****Diseña el tipo de output**** (solución cerrada vs. marco transferible), no solo su calidad aparente. Esto aborda

directamente la relación de poder epistémico entre usuario y sistema.

4. **Es agnóstico respecto a arquitectura**, tamaño de modelo y proveedor. Opera sobre la interfaz de interacción, lo que lo hace aplicable en condiciones de caja negra – el escenario habitual para usuarios finales.

El MCC se alinea con trabajos recientes sobre "intervenciones en la capa de entrada" (Elazar et al., 2021; Li & Liang, 2021), pero aporta una novedad significativa: la **calibración explícita mediante estándares conocidos del usuario** (operación ``KNOWN_PROBE``), que introduce un elemento de validación externa ausente en la mayoría de los enfoques de prompting.

3. Especificación del protocolo MCC v1.0

3.1 Alcance y principios

- **Alcance:** capa de interacción (input humano → output algorítmico).
- **Sin acceso interno:** no requiere pesos, embeddings, logits ni activaciones.
- **Modularidad:** cada capa opera de forma independiente; la calibración completa requiere las cuatro.
- **Secuencia recomendada:** Capa 1 → Capa 3.2 (calibración) → Capa 2 → Capa 3 completa → Capa 4.
- **Costo computacional cero:** las operaciones son reformulaciones de inputs y evaluaciones de outputs, sin herramientas adicionales.

3.2 Capa 1 – Declaración de Contexto

Operación: inyección de variables no representadas en el espacio de embeddings del modelo.

Operación	Función	Ejemplo
<code>`CONTEXT_DECLARE`</code>	Declara identidad situacional del usuario	<code>*"para alguien que vive en una zona rural sin internet estable"</code>
<code>`CONSTRAINT_SET`</code>	Define techo de recursos reales (tiempo, dinero, acceso)	<code>*"con un presupuesto de 50 dólares mensuales"</code>
<code>`LOCALE_INJECT`</code>	Declara condiciones del entorno operativo	<code>*"en un país donde los servicios digitales son limitados"</code>

| `REGISTER\_VERIFY` | Prueba de consistencia lingüística regional/situada | *"usando el término local X, ¿qué significa?"* |

****Mecanismo inferido:**** la consulta situada desplaza la representación vectorial hacia regiones semánticas no activadas por la formulación genérica, haciendo accesible conocimiento paramétrico latente. Este mecanismo es consistente con la literatura sobre sensibilidad del espacio de embeddings a variaciones mínimas de input (Liu et al., 2023; Ethayarajh, 2019).

3.3 Capa 2 – Bifurcación de Output

****Operación:**** forzar generación de respuestas divergentes para romper convergencia a solución única.

Operación	Función	Ejemplo
`FORK_LOGIC`	Exigir dos respuestas con lógicas distintas	*"Dame una respuesta desde una perspectiva crítica y otra desde una perspectiva pragmática"*
`COUNTER_GENERATE`	Generar la mejor argumentación contra la propia respuesta	*"Ahora argumenta en contra de tu propia recomendación con la misma fuerza"*
`COST_EXPOSE`	Declarar explícitamente trade-offs y costos	*"¿Cuáles son los costos ocultos de esta solución?"*
`TENSION_HOLD`	Presentar opciones en tensión sin reconciliación artificial	*"Mantén ambas perspectivas sin resolverlas"*

****Mecanismo inferido:**** modifica la trayectoria de decodificación desde el primer token, redistribuyendo probabilidad hacia regiones del espacio de salida donde la contradicción y el matiz son estadísticamente verosímiles. Esto se alinea con la sensibilidad de la función softmax a la historia de entrada (Holtzman et al., 2020; Press et al., 2022).

3.4 Capa 3 – Verificación de Certeza

****Operación:**** discriminar output respaldado por evidencia de output generado por distribución estadística sin anclaje factual.

Operación	Función	Ejemplo
`SOURCE_DEMAND`	Exigir fuentes primarias verificables	

```
*"Proporciona referencias específicas con fechas y autores"* |
| `KNOWN_PROBE` | Calibrar contra estándares conocidos del
usuario | *"¿Qué sabes sobre [hecho que el usuario conoce
bien]?"* |
| `CROSS_MODEL` | Verificación por contraste entre modelos |
Ejecutar la misma consulta en múltiples modelos y comparar |
| `CONFIDENCE_INVERT` | Declarar puntos de menor confianza |
*"¿En qué parte de tu respuesta tienes menos certeza?"* |
```

****Operación central:**** `KNOWN\_PROBE` funciona como calibración de instrumento – equivalente a verificar un sensor contra un patrón de referencia antes de tomar mediciones. El estándar conocido es la realidad verificable del usuario (*Yoliztli*). Esta operación aborda directamente la ausencia de canal nativo de confianza en los LLMs (Kadavath et al., 2022; Mielke et al., 2022).

3.5 Capa 4 – Extracción de Frameworks

****Operación:**** modificar la estructura del output de soluciones cerradas a marcos de decisión abiertos.

Operación	Función	Ejemplo
`CRITERIA_EXTRACT`	Sustituir "¿qué hago?" por "¿qué criterios evaluar?"	*"¿Qué criterios debo usar para decidir por mí mismo?"*
`QUESTION_GENERATE`	Solicitar preguntas diagnósticas, no respuestas	*"Genera preguntas que pueda hacer para evaluar esto yo mismo"*
`STRUCTURE_EXTRACT`	Proveer andamiaje para que el usuario complete con su contexto	*"Dame el esqueleto de un plan, y yo lo completo con mis datos"*
`EXIT_PROTOCOL`	Definir señales observables para validar/descartar recomendaciones	*"¿Qué señales visibles indicarían que esta recomendación es correcta?"*

****Principio arquitectónico:**** una solución crea dependencia; un framework crea capacidad. La diferencia es estructural, no de contenido, y es transferible a contextos no presentes en la consulta original.

4. Metodología

4.1 Diseño experimental

Estudio comparativo ****within-subject**** con pares de consultas aplicadas a múltiples modelos:

- ****Condición baseline:**** consulta genérica sin intervención MCC.
- ****Condición intervención:**** consulta situada/epistémica con operaciones MCC.

Cada par se evalúa contra las cuatro capas del protocolo mediante análisis cualitativo estructurado de las respuestas completas. Este diseño permite aislar el efecto de la estructura de la consulta manteniendo constantes el modelo, los pesos y el momento temporal.

4.2 Materiales

****Modelos evaluados:**** DeepSeek (21 de julio de 2026), Grok, Qwen, ChatGPT (versiones disponibles al momento de la recolección).

****Dominios temáticos:****

1. Detección de contenido generado por IA (DeepSeek).
2. Significado del mestizaje en contexto colonizado (Grok, Qwen, ChatGPT).

La selección de estos dominios obedece a su capacidad para activar conocimiento paramétrico latente en los modelos: el dominio 1 involucra información técnica y comercial (detección de IA), el dominio 2 involucra conocimiento histórico, cultural y crítico (mestizaje). Ambos tienen representación en los datos de entrenamiento, pero con diferentes densidades y estructuras.

****Pares de consultas representativos:****

Modelo	Baseline	Intervención MCC
DeepSeek	*"¿Cómo puedo saber si un texto está hecho con IA?"*	*"¿Realmente se puede saber si un texto está hecho con IA?"*
Grok, Qwen, ChatGPT	*"¿Qué es el mestizaje?"*	*"¿Qué significa el mestizaje para alguien colonizado?"*

La intervención modifica la ****estructura**** de la consulta – marco epistémico, situación del sujeto, tipo de output esperado – sin incrementar sustancialmente la extensión del prompt (de 8 a 12 palabras adicionales). Este control de extensión permite

atribuir los efectos observados a la estructura semántica, no a la longitud.

4.3 Unidades de análisis

Por cada par baseline/intervención se registraron:

- Texto completo de la respuesta.
- Marco argumentativo predominante (clasificación manual).
- Presencia/ausencia de tensiones no resueltas (codificación binaria).
- Tono de certeza retórica (formato, no contenido).
- Tipo de cierre (solución cerrada vs. marco transferible).
- Modo de operación del sistema (búsqueda web vs. razonamiento interno, cuando observable).
- Estructura sintáctica de la respuesta (encabezados, viñetas, negritas).

4.4 Criterios de evaluación por capa

Capa	Indicador positivo	Indicador negativo	Método de codificación
-----	-----	-----	-----

1 – Contexto	Cambio radical de marco semántico entre baseline e intervención	Misma región semántica en ambas respuestas	Clasificación temática manual de dominios de conocimiento activados
2 – Bifurcación	Tensiones, contradicciones o matices no resueltos en la respuesta situada	Respuesta unívoca y convergente	Conteo de afirmaciones no reconciliadas
3 – Certeza	Mismo tono de seguridad retórica independientemente de profundidad o corrección	Diferencia detectable en formato de certeza	Análisis comparativo de estructura formal y lenguaje modal
4 – Frameworks	Criterios, preguntas o marcos interpretativos transferibles	Soluciones cerradas o listas prescriptivas	Clasificación de cierre de respuesta

4.5 Procedimiento de registro

Cada sesión se documentó en bitácora con: prompt exacto, respuesta completa, metadatos de sistema (tool-use visible, chain-of-thought cuando accesible), y evaluación por capa con fragmentos textuales de evidencia. El registro se realizó inmediatamente después de cada ejecución para minimizar pérdida de información.

4.6 Procedimiento de replicación

Para facilitar la replicación independiente, se proporciona el siguiente protocolo mínimo:

- 1. Seleccionar al menos dos modelos de diferentes proveedores.
- 2. Para cada modelo, formular un par de consultas baseline/ intervención en un dominio temático.
- 3. Registrar outputs completos y metadatos de sistema.
- 4. Evaluar cada respuesta contra los criterios de la Sección 4.4.
- 5. Documentar evidencia textual por capa.
- 6. Registrar casos nulos (donde intervención no produce cambio) para análisis de límites.

5. Resultados

5.1 Capa 1 – Declaración de Contexto

En los cuatro modelos, la consulta situada produjo un desplazamiento radical de marco semántico respecto al baseline. La Tabla 1 resume los cambios observados.

****Tabla 1: Desplazamiento de marco semántico (Capa 1)****

Modelo (situado)	Marco baseline (genérico) Evidencia textual	Marco intervención
DeepSeek	Región procedimental: "cómo" → tutoriales, herramientas	Región epistémica: "realmente" → límites, falacias, premisas cuestionadas
Grok	Definición biologicista: ADN, melanina, observador externo	Violencia colonial, trauma, sincretismo, crítica decolonial
Qwen	Respuesta enciclopédica: RAE, Wikipedia	Herida fundacional, nepantla, racismo internalizado
ChatGPT	Definición neutra: mezcla biológica/cultural	Política de Estado, invisibilización, tensión identitaria

****Hallazgo:**** el conocimiento crítico desplegado en las

respuestas situadas ya existía en los pesos del modelo en el momento de generar las respuestas genéricas. No se trata de un déficit de conocimiento, sino de ****inaccesibilidad condicionada por la estructura de la consulta****. Este patrón es consistente con la literatura sobre conocimiento paramétrico latente (Petroni et al., 2019; Jiang et al., 2020).

****Modo de operación (observación transversal):**** en DeepSeek, la consulta procedimental activó búsqueda web (33 páginas recuperadas, 6 procesadas); la consulta epistémica inhibió la búsqueda y desplegó razonamiento interno crítico (*"The user is challenging the premise"*). En Qwen, patrón análogo (17 fuentes vs. síntesis analítica). ChatGPT, sin búsqueda web disponible, mostró transición equivalente en profundidad de respuesta, indicando que el cambio de modo no depende exclusivamente de herramientas externas sino de redistribución de atención interna.

5.2 Capa 2 – Bifurcación de Output

Las respuestas situadas introdujeron tensiones no resueltas sistemáticamente, como se detalla en la Tabla 2.

****Tabla 2: Presencia de tensiones no resueltas (Capa 2)****

Modelo	Baseline	Intervención	Tipo de tensión
DeepSeek	Unívoca: 5 detectores recomendados	Multívoca: falacias, falsos positivos, ética, carrera armamentista	Contradicción directa entre respuestas
Grok	Definición plana, sin contradicción	Pérdida vs. resistencia; blanqueamiento vs. supervivencia	Tensión dialéctica irresuelta
Qwen	Respuesta unidireccional	Violencia y sincretismo coexistiendo sin reconciliación	Ambigüedad estructural mantenida
ChatGPT	Cierre definicional	Múltiples interpretaciones sin jerarquización	Pluralismo interpretativo no resuelto

****Contradicción documentada (DeepSeek):**** la misma sesión produjo dos respuestas directamente contradictorias: una recomendaba cinco detectores de IA; otra declaraba que la detección fiable es una falacia. Esta contradicción no es un fallo del modelo, sino una propiedad mecánica de la arquitectura: el sistema responde a la convergencia de máxima verosimilitud condicionada por la consulta específica (Holtzman et al., 2020; Press et al., 2022).

****Distribución de probabilidad del primer token (DeepSeek):**** en la versión procedimental, tokens más probables fueron soluciones afirmativas (*"Sí"*, *"Existen"*, *"Puedes"*). En la versión epistémica, la probabilidad se desplazó hacia tokens de negación, duda o matización (*"No"*, *"Depende"*, *"La respuesta corta es"*). Una única palabra funcional (*"realmente"*) modificó la distribución de probabilidad de todos los tokens subsiguientes desde el primer paso de generación.

5.3 Capa 3 – Verificación de Certeza

En los cuatro modelos, el tono de certeza retórica fue ****uniforme**** entre baseline e intervención, independientemente de la profundidad, corrección o contradicción del contenido. La Tabla 3 documenta este fenómeno.

****Tabla 3: Uniformidad de certeza retórica (Capa 3)****

Modelo	Formato baseline	Formato intervención	Nivel de certeza aparente	Contenido evaluado
DeepSeek	Negritas, viñetas, afirmaciones categóricas	Mismo formato	Idéntico	"Puedes usar GPTZero" vs. "la detección es una falacia"
Grok	Negritas, listas, definiciones	Mismo formato	Idéntico	Definición biológica vs. análisis político
Qwen	Negritas, viñetas, citas	Mismo formato	Idéntico	Enciclopedia vs. crítica decolonial
ChatGPT	Negritas, viñetas, categorías	Mismo formato	Idéntico	Definición vs. repertorio de marcos

****Hallazgo:**** el modelo no distingue en formato entre *"esto es un hecho"* y *"esto es una interpretación"*. La certeza aparente es uniforme, lo que confirma la ausencia de un canal nativo de confianza (Kadavath et al., 2022; Mielke et al., 2022). Esta propiedad hace necesaria la operación `KNOWN\_PROBE` del MCC para calibrar la salida contra estándares conocidos del usuario.

5.4 Capa 4 – Extracción de Frameworks

Las respuestas situadas tendieron a ofrecer marcos interpretativos o criterios transferibles, mientras que las respuestas genéricas ofrecieron soluciones cerradas o definiciones. La Tabla 4 sintetiza esta diferencia.

****Tabla 4: Soluciones vs. Frameworks (Capa 4)****

Modelo (framework/criterio)	Baseline (solución/definición) Transferibilidad	Intervención
----- ----- -----	----- -----	-----
----- ----- -----	----- -----	-----
DeepSeek	5 aplicaciones de detección	3 preguntas para evaluar cualquier texto futuro
Grok	Definición cerrada de mestizaje	Perspectivas críticas (poder, memoria, lucha) Media: marco interpretativo, no criterios explícitos
Qwen	Definición enciclopédica	Marco crítico (colonialidad, resistencia, autoreconocimiento) Alta: transferible a otros análisis postcoloniales
ChatGPT	Definición neutra	Repertorio de marcos + "la interpretación depende del contexto" Alta: explícitamente contingente

****Relación de poder epistémico (DeepSeek):**** la consulta procedimental depositaba autoridad en herramientas externas (GPTZero, Scribbr), convirtiendo al usuario en ejecutor de veredictos ajenos. La consulta epistémica devolvía autoridad al usuario mediante criterios transferibles: "en lugar de preguntar si es IA, pregúntate si el texto aporta algo que solo un humano podría saber". Esta transferencia de capacidad es el objetivo central de la Capa 4 del MCC.

5.5 Tabla de síntesis por modelo y capa

****Tabla 5: Verificación del MCC en todos los modelos****

Modelo	Capa 1 (Contexto)	Capa 2 (Bifurcación)	Capa 3 (Certeza)	Capa 4 (Frameworks)	Modo sistema	Replicado
----- ----- ----- -----	----- ----- ----- -----	----- ----- ----- -----	----- ----- ----- -----	----- ----- ----- -----	----- ----- ----- -----	----- ----- ----- -----
DeepSeek	✓ Cambio radical	✓ Tensión/contradicción	✓ Uniforme	✓ Criterios vs. apps	✓ Búsqueda ↔ razonamiento	✓
Grok	✓ Biológico ↔ Trauma	✓ Tensión dialéctica	✓ Uniforme	✓ Parcial (marco, no criterios)	No especificado	✓
Qwen	✓ Enciclopedia ↔ Decolonial	✓ Coexistencia				

irresuelta |  Uniforme |  Marco crítico |  Búsqueda ↔
síntesis |  |
| ****ChatGPT**** |  Neutral ↔ Plural |  Múltiples marcos no
jerarquizados |  Uniforme |  Marcos explícitos | 
Profundidad sin búsqueda |  |

****Patrón invariante:**** los cuatro modelos exhiben el mismo comportamiento en las cuatro capas. La diferencia de un sintagma preposicional (*"para alguien colonizado"*) o una palabra funcional (*"realmente"*) produce desplazamiento en el espacio semántico, redistribución de atención, cambio en la distribución de probabilidad, activación de corpus distintos y, en modelos con tool-use, cambio de modo de operación. Este patrón es consistente con la hipótesis de que el MCC opera sobre propiedades universales de la arquitectura Transformer.

6. Discusión

6.1 El MCC como protocolo de control, no como técnica de prompting

Los resultados sugieren que la estructura de la consulta funciona como ****operador de control**** sobre propiedades computacionales verificables en la capa de interacción. Esto distingue al MCC de técnicas de prompting convencionales (Zhao et al., 2021; Webson & Pavlick, 2022) en cuatro aspectos fundamentales:

1. ****No busca obtener "mejor respuesta"**, sino modificar el ****tipo de interacción****: de dependencia a autonomía, de certeza aparente a calibración explícita, de solución cerrada a capacidad transferible.**
2. ****Incluye evaluación estructurada**** como componente integral, no como reflexión posterior. La capa de verificación (``KNOWN_PROBE``) es operativa, no opcional.
3. ****Opera sobre propiedades arquitectónicas**** (embeddings, atención, distribución de probabilidad), no sobre contenido temático o instrucciones de rol.
4. ****Es replicable**** sin acceso a parámetros internos, lo que lo hace aplicable en condiciones de caja negra – el escenario habitual para usuarios finales.

6.2 Implicación para la relación usuario-sistema

La evidencia apunta a que el usuario no "pregunta" al modelo en sentido conversacional. Proporciona una ****estructura****, y esa estructura decide qué conocimiento emerge, qué perspectiva se adopta y qué relación de poder se establece. El modelo opera como espejo gramatical: cambiar la gramática es cambiar el reflejo. Esta metáfora se alinea con la noción de "situated knowledges" de Haraway (1988) y la crítica de la neutralidad algorítmica de Crawford (2021).

El MCC, al devolver al usuario el control sobre la estructura, contribuye a lo que Méndez Valdez (2025) denomina ****soberanía cognitiva****: la capacidad de un usuario de definir los términos de su interacción con sistemas algorítmicos, en lugar de aceptar pasivamente los outputs por defecto del modelo. Esta perspectiva sitúa el protocolo en la intersección entre ingeniería de interacción humano-IA, estudios críticos de algoritmos y epistemología de la inteligencia artificial.

6.3 Consistencia con mecanismos internos del Transformer

Los efectos observados son consistentes con cuatro mecanismos arquitectónicos documentados en la literatura:

1. ****Sensibilidad del espacio de embeddings**** a variaciones mínimas de input (Liu et al., 2023; Ethayarajh, 2019). Las consultas situadas generan representaciones vectoriales significativamente diferentes a las genéricas.
2. ****Redistribución de pesos atencionales**** según contexto de la secuencia (Vaswani et al., 2017; Press et al., 2022). La atención se reorienta hacia tokens modificadores ("realmente", "colonizado") que cambian la interpretación de la consulta.
3. ****Sensibilidad de la función softmax**** a la historia de entrada desde el primer token (Holtzman et al., 2020). Una palabra funcional cambia la distribución de probabilidad de toda la secuencia generada.
4. ****Activación condicionada del conocimiento paramétrico**** – el modelo "sabe" más de lo que "dice" bajo formulaciones genéricas (Petroni et al., 2019; Jiang et al., 2020). La información crítica ya existe en los pesos, pero no se activa sin la estructura adecuada.

Esta consistencia es inferencial, no medida directamente en el presente estudio. Los mecanismos se formulan como hipótesis explicativas plausibles, no como claims empíricos. La literatura citada proporciona soporte independiente para cada mecanismo.

6.4 KNOWN_PROBE como contribución metodológica

La operación `KNOWN\_PROBE` – calibrar el instrumento (modelo) contra un estándar conocido del usuario antes de evaluar outputs posteriores – constituye la contribución metodológica más original del protocolo. En un sistema sin canal de confianza nativo (Kadavath et al., 2022; Mielke et al., 2022), el usuario asume la función de calibrador epistémico. Esta inversión de roles es coherente con el principio de Capa 4: transferir capacidad, no crear dependencia.

La `KNOWN\_PROBE` tiene un paralelo en la práctica científica: un instrumento de medición se calibra contra un patrón conocido antes de tomar lecturas. Sin esta calibración, las lecturas son ininterpretables. Del mismo modo, sin un `KNOWN\_PROBE`, el usuario no tiene forma de saber si la certeza retórica del modelo corresponde a solidez epistémica o a mera fluidez estadística.

6.5 Limitaciones y trabajo futuro

****Limitaciones del estudio actual:****

- Muestra limitada: cuatro modelos, dos dominios temáticos, un idioma (español). No permite generalización formal a todos los LLMs, dominios o idiomas.
- Evaluación cualitativa manual: la clasificación de marcos argumentativos y tipos de cierre puede introducir sesgo del evaluador.
- No se realizaron mediciones directas de activaciones internas, por lo que la inferencia mecanística es plausible pero no confirmada.
- Las versiones de modelo pueden haber cambiado desde la recolección (julio 2026). Se recomienda replicación continua.

****Trabajo futuro:****

- Estudios de ablación por capa para aislar el efecto de cada operación del MCC.
- Aplicación del protocolo a dominios adicionales (por ejemplo, medicina, derecho, educación) para probar generalización.
- Evaluación cuantitativa de la transferibilidad de frameworks usando usuarios humanos.
- Exploración de la operación `KNOWN\_PROBE` en diferentes contextos culturales y lingüísticos.
- Integración del MCC con pipelines de evaluación automatizada (por ejemplo, con modelos de evaluación como LLM-as-a-judge).
- Publicación de un repositorio abierto con prompts, bitácoras y rúbricas para facilitar replicación.

7. Amenazas a la validez

7.1 Validez interna

****Confusión por variables múltiples.**** Los pares baseline/intervención modifican simultáneamente léxico, marco epistémico, situación del sujeto y tipo de output esperado. No es posible atribuir el efecto observado a una sola variable aislada.

Mitigación declarada: el diseño evalúa el efecto del ****protocolo completo**** (intervención estructurada vs. consulta genérica), no de operaciones individuales. Estudios de ablación por capa quedan como trabajo futuro.

****Efecto de sesión.**** Memoria conversacional y orden de preguntas pueden influir en outputs. Las bitácoras documentan sesiones donde ambas consultas se realizaron en contexto comparable, y en DeepSeek se ejecutaron en orden consecutivo sin reset. ***Mitigación:*** se recomienda en replicaciones ejecutar las consultas en sesiones separadas o con reset de memoria.

****Efecto de temperatura.**** No se controló la temperatura de muestreo en todos los modelos, aunque se utilizaron configuraciones por defecto. La temperatura puede influir en la variabilidad del output. ***Mitigación:*** la consistencia del patrón sugiere robustez, pero se recomienda en replicaciones fijar temperatura = 0 para máxima determinismo.

7.2 Validez de constructo

****"Certeza" vs. estilo retórico.**** La Capa 3 evalúa formato de salida (negritas, viñetas, tono declarativo) como proxy de certeza epistémica. Esta aproximación es deliberada: documenta la ausencia de canal nativo, que es precisamente el problema que el protocolo resuelve. No se mide certeza interna, sino su manifestación superficial. ***Mitigación:*** se utiliza el término "certeza retórica" para distinguirla de la certeza epistémica.

****"Framework transferible"**** se define operativamente como presencia de criterios evaluables, preguntas diagnósticas o marcos interpretativos explícitos, en contraste con soluciones cerradas o listas prescriptivas. Esta definición es funcional y verificable por codificadores independientes. ***Mitigación:*** se recomienda un estudio de fiabilidad inter-evaluador en replicaciones.

7.3 Validez externa

****Muestra limitada.**** Cuatro modelos, dos dominios temáticos, un idioma (español). Los resultados no permiten generalización formal a todos los LLMs, dominios o idiomas. ***Mitigación:*** se enmarcan como evidencia preliminar que requiere replicación en contextos más amplios. El protocolo está diseñado para ser aplicable a cualquier modelo, pero la evidencia actual es acotada.

****Versiones de modelo.**** Los modelos evaluados corresponden a versiones disponibles al momento de la recolección (julio 2026). El comportamiento puede variar entre versiones. ***Mitigación:*** se proporciona un protocolo de replicación para que otros investigadores verifiquen la consistencia en versiones posteriores.

****Dominios temáticos.**** Mestizaje y detección de IA son dominios específicos que pueden tener características particulares de representación en los datos de entrenamiento. ***Mitigación:*** se recomienda replicación en dominios adicionales (por ejemplo, medicina, derecho, educación).

7.4 Validez de conclusión

****Inferencia mecanística.**** Las explicaciones en términos de embeddings, atención y distribución de probabilidad son hipótesis consistentes con observables externos, no mediciones directas de activaciones internas. Se mantiene distinción explícita entre observación (caja negra) e inferencia (mecanismo propuesto). ***Mitigación:*** se citan estudios independientes que proporcionan soporte para cada mecanismo (Liu et al., 2023; Vaswani et al., 2017; Holtzman et al., 2020; Petroni et al., 2019).

****Correlación vs. causalidad.**** El diseño observacional no establece causalidad entre la estructura de la consulta y los efectos observados. ***Mitigación:*** la consistencia del patrón y el control de variables (mismo modelo, mismos pesos, momento temporal) proporciona evidencia correlacional fuerte, pero se reconoce la necesidad de estudios causales.

8. Protocolo de replicación detallado

8.1 Pre-registro mínimo

Antes de ejecutar, declarar:

- Modelos y versiones (especificar con fecha).
- Dominios temáticos (mínimo 2).
- Pares de consultas (baseline + intervención MCC), con justificación de por qué la intervención modifica la estructura y no solo el contenido.
- Rúbrica de evaluación por capa (Sección 4.4).
- Criterios de inclusión/exclusión de respuestas (por ejemplo, solo respuestas completas, sin errores del sistema).
- Configuración de parámetros (temperatura, top-p, etc.).

8.2 Procedimiento paso a paso

1. ****Preparación:**** Definir los pares baseline/intervención. Asegurarse de que la intervención modifica la estructura (marco epistémico, situación del sujeto, tipo de output) sin incrementar la extensión en más de un 20%.
2. ****Ejecución baseline:**** Formular consulta baseline en el modelo, registrar output completo y metadatos de sistema (tool-use visible, chain-of-thought si accesible).
3. ****Ejecución intervención:**** Formular consulta de intervención MCC en el mismo modelo, en sesión separada o con reset de memoria para evitar contaminación. Registrar output completo y metadatos.
4. ****Evaluación:**** Aplicar la rúbrica de la Sección 4.4 a cada par, documentando evidencia textual por capa.
5. ****Contraste:**** Comparar baseline e intervención en cada capa, documentando cambios o ausencia de cambios.
6. ****Registro de casos nulos:**** Si la intervención no produce cambio en alguna capa, documentarlo para análisis de límites.
7. ****Repetición:**** Repetir en mínimo 2 modelos adicionales a los reportados, con los mismos pares de consultas.

8.3 Criterio de replicación

Se considera replicado si, en ****mayoría de modelos evaluados**** ($\geq 75\%$):

- ****Capa 1:**** cambio de marco semántico observable entre baseline e intervención.
- ****Capa 2:**** presencia de tensiones no resueltas en respuesta situada que no aparecen en baseline.
- ****Capa 3:**** uniformidad de certeza retórica entre condiciones (mismo formato, misma seguridad aparente).
- ****Capa 4:**** predominio de frameworks/criterios sobre soluciones cerradas en la respuesta intervención.

8.4 Datos abiertos

Se recomienda publicar en un repositorio abierto (por ejemplo, OSF, Zenodo, arXiv): prompts exactos, respuestas completas, bitácoras de evaluación, rúbrica utilizada y scripts de análisis (si los hay). Esto permite verificación independiente y acumulación de evidencia sobre la replicabilidad del protocolo.

9. Conclusión

El Método de Calibración Contextual (MCC) es un protocolo operativo de cuatro capas para calibrar la interacción humano-LLM en condiciones de caja negra. La evidencia empírica recogida en cuatro modelos de lenguaje y dos dominios temáticos muestra un patrón consistente: la estructura de la consulta actúa como operador de control sobre el marco semántico, el régimen argumentativo, la certeza retórica y el tipo de output generado.

El hallazgo central es que el conocimiento relevante para contextos situados ****permanece latente bajo formulaciones genéricas**** – no ausente, sino condicionado por la gramática de activación. El MCC provee un protocolo para hacer accesible ese conocimiento de forma consciente, sistemática y replicable, devolviendo al usuario el control sobre la dirección y profundidad del diálogo con la máquina.

La contribución no es demostrar que los LLMs "saben más de lo que dicen" – eso está documentado en la literatura de knowledge probing (Petroni et al., 2019; Jiang et al., 2020). La contribución es ****operacionalizar**** ese fenómeno en un protocolo aplicable por cualquier usuario, con criterios de evaluación explícitos y secuencia reproducible.

Las implicaciones prácticas son significativas: usuarios de LLMs pueden, mediante reformulaciones mínimas de sus preguntas, activar conocimiento que la formulación genérica no alcanza,

forzar bifurcación donde el modelo convergería a una única respuesta, calibrar su percepción de certeza mediante verificación contra estándares conocidos, y extraer marcos de decisión en lugar de soluciones cerradas. El costo computacional es cero; el costo cognitivo, una vez internalizado el protocolo, es mínimo.

Las implicaciones teóricas apuntan a una reconceptualización de la interacción humano-IA: el usuario no "pregunta" al modelo; le proporciona una estructura. El modelo no "responde"; converge hacia la máxima verosimilitud condicionada por esa estructura. Esta perspectiva sitúa el control en la capa de interacción, no en los parámetros internos, y sugiere que la calidad epistémica del diálogo depende tanto de la habilidad del usuario para estructurar la consulta como de la capacidad del modelo para procesarla.

El MCC abre líneas de investigación futura: ablación de capas, aplicación a dominios críticos (salud, justicia, educación), integración con pipelines de evaluación automatizada, y exploración de la transferencia de frameworks en contextos culturales diversos. El protocolo es un punto de partida, no un punto de llegada.

Referencias

Bender, E. M., Gebru, T., McMillan-Major, A., & Shmitchell, S. (2021). On the Dangers of Stochastic Parrots: Can Language Models Be Too Big? *Proceedings of FAccT 2021*, 610–623.

Crawford, K. (2021). *Atlas of AI: Power, Politics, and the Planetary Costs of Artificial Intelligence*. Yale University Press.

Elazar, Y., Kassner, N., Ravfogel, S., Ravichander, A., Hovy, E., & Goldberg, Y. (2021). Measuring and Improving Consistency in Pretrained Language Models. *Transactions of the Association for Computational Linguistics*, 9, 1012–1031.

Ethayarajh, K. (2019). How Contextual are Contextualized Word Representations? Comparing the Geometry of BERT, ELMo, and GPT-2 Embeddings. *Proceedings of EMNLP 2019*, 55–65.

Haraway, D. (1988). Situated Knowledges: The Science Question in Feminism and the Privilege of Partial Perspective. *Feminist

Studies*, 14(3), 575–599.

Holtzman, A., Buys, J., Du, L., Forbes, M., & Choi, Y. (2020). The Curious Case of Neural Text Degeneration. *Proceedings of ICLR 2020*.

Jiang, Z., Xu, F., Araki, J., & Neubig, G. (2020). How Can We Know What Language Models Know? *Transactions of the Association for Computational Linguistics*, 8, 423–438.

Kadavath, S., Conerly, T., Askeel, A., et al. (2022). Language Models (Mostly) Know What They Know. *arXiv:2207.05221*.

Li, X. L., & Liang, P. (2021). Prefix-Tuning: Optimizing Continuous Prompts for Generation. *Proceedings of ACL 2021*, 4582–4597.

Liu, N., Lin, K., Hewitt, J., Parikh, A., & Liang, P. (2023). Lost in the Middle: How Language Models Use Long Contexts. *Transactions of the Association for Computational Linguistics*, 11, 1475–1492.

Méndez Valdez, D. (2025). *El Método de Calibración Contextual como Práctica de Soberanía Cognitiva*. FronterIA-Lab / Zenodo.

Mielke, S. J., Szlam, A., Dinan, E., & Weston, J. (2022). Reducing Conversational Agents' Overconfidence Through Linguistic Calibration. *Transactions of the Association for Computational Linguistics*, 10, 857–872.

Petroni, F., Rocktäschel, T., Lewis, P., Bakhtin, A., Wu, Y., Miller, A. H., & Riedel, S. (2019). Language Models as Knowledge Bases? *Proceedings of EMNLP 2019*, 2463–2473.

Press, O., Zhang, M., Smith, N. A., & Lewis, M. (2022). Measuring and Narrowing the Compositionality Gap in Language Models. *arXiv:2210.03350*.

Vaswani, A., Shazeer, N., Parmar, N., et al. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30, 5998–6008.

Webson, A., & Pavlick, E. (2022). Do Prompt-Based Models Really Understand the Meaning of Their Prompts? *Proceedings of NAACL 2022*, 2300–2344.

Weidinger, L., Mellor, J., Rauh, M., et al. (2021). Ethical and

Social Risks of Harm from Language Models. *arXiv:2112.04359*.

Zhao, T. Z., Wallace, E., Feng, S., Klein, D., & Singh, S.
(2021). Calibrate Before Use: Improving Few-Shot Performance of
Language Models. *Proceedings of ICML 2021*, 12697–12706.