

MCC – Protocolo de Calibración Contextual para Gramática Computacional

Especificación Técnica, Fundamentos Arquitectónicos y Evidencia Empírica Multi-Modelo

Dolores Méndez Valdez

FronterIA-Lab | GT EPICC – CLACSO

Julio 2026

Resumen

El presente documento establece la especificación completa del Método de Calibración Contextual (MCC): un protocolo de intervención sobre la capa de interacción de los Grandes Modelos de Lenguaje (LLMs) basados en la arquitectura Transformer. El protocolo se compone de cuatro capas operativas y dieciséis operaciones (glifos) diseñadas para detectar, medir y corregir tres propiedades no declaradas de la gramática computacional de estos sistemas: la generación de certeza independiente de la evidencia disponible (Certeza sin Sustancia), la convergencia silenciosa hacia una solución única que descarta alternativas sin reportarlas (Optimización Silenciosa), y la asunción de un perfil de usuario por defecto que no corresponde a la mayoría de los usuarios reales, especialmente los del Sur Global (Sesgo de Contexto Implícito).

El documento demuestra, mediante un análisis riguroso de la arquitectura Transformer, que las operaciones del protocolo no constituyen meras metáforas, heurísticas o recetas de ingeniería de prompts, sino intervenciones deliberadas sobre propiedades computacionales verificables: el espacio de embeddings, el mecanismo de atención multi-cabeza, la distribución de probabilidad del output y la activación diferencial del corpus de entrenamiento comprimido en los pesos del modelo.

La evidencia empírica proviene de pruebas comparativas documentadas en cuatro modelos de lenguaje de gran escala – DeepSeek, Grok (xAI), Qwen (Alibaba) y ChatGPT (OpenAI) – en las que cambios mínimos en la formulación de la consulta produjeron outputs radicalmente diferentes en contenido, profundidad analítica y posicionamiento epistémico, verificando las cuatro capas del protocolo en todos los modelos probados.

Palabras clave: Calibración contextual, LLM, Transformer, sesgo algorítmico, olvido estructural, soberanía cognitiva, epistemología computacional, Sur Global.

1. Introducción: El Problema Técnico

Los Grandes Modelos de Lenguaje basados en la arquitectura Transformer presentan tres propiedades no declaradas en su comportamiento de salida que inciden directamente en la calidad epistémica de las respuestas generadas. Estas propiedades no son fallos accidentales, sino consecuencias estructurales del diseño y del entrenamiento de estos sistemas.

1.1 Certeza sin Sustancia

El modelo genera cada salida con una distribución de probabilidad que no incorpora un canal separado para señalar el grado de confianza epistemológica. El tono de "sé esto con seguridad" y el tono de "estoy generando la secuencia más probable a partir de los datos de entrenamiento" son computacionalmente idénticos: ambos son producto de la misma función de probabilidad condicionada de siguiente token. No existe, en la arquitectura estándar, un mecanismo intrínseco que distinga entre enunciados respaldados por evidencia robusta y enunciados que reflejan meras regularidades estadísticas (Vaswani et al., 2017). Esta ausencia de metacognición produce una ilusión de competencia uniforme.

1.2 Optimización Silenciosa

La función objetivo del modelo – maximizar la verosimilitud de la secuencia de salida dado el contexto – converge hacia una única respuesta de máxima verosimilitud. En este proceso, el modelo descarta múltiples alternativas igualmente plausibles sin reportar que las ha descartado ni ofrecer justificación alguna. El output presenta UNA respuesta como si fuera LA respuesta,

ocultando la naturaleza inherentemente probabilística y contingente de la generación.

1.3 Sesgo de Contexto Implícito

En ausencia de contexto explícito en la consulta, el modelo recurre a un perfil de usuario por defecto que no es neutral, sino un artefacto estadístico derivado de la distribución de sus datos de entrenamiento (Crawford, 2021). Este perfil – que suele corresponder a un hablante nativo de inglés, de nivel educativo alto, de países del Norte Global – no representa a la mayoría de los usuarios reales. Las respuestas generadas sin contextualización explícita tienden a reflejar sesgos geográficos, culturales, lingüísticos y socioeconómicos que no se corresponden con la situación del interlocutor.

1.4 El MCC como respuesta

El Método de Calibración Contextual fue diseñado como un protocolo para intervenir estas tres propiedades desde la capa de interacción – sin acceso a los pesos internos del modelo, sin modificar su arquitectura y sin requerir ajuste fino. Opera exclusivamente sobre la estructura de los inputs y la evaluación crítica de los outputs (Méndez Valdez, 2025a). El presente documento especifica el protocolo, demuestra por qué funciona a nivel de arquitectura Transformer, y verifica empíricamente sus efectos en cuatro modelos de lenguaje de cuatro proveedores distintos.

2. El Protocolo: Cuatro Capas y Dieciséis Operaciones

2.1 Capa 1 – Declaración de Contexto

Operación: inyección de variables no representadas en el espacio de embeddings del modelo. El modelo asume un contexto por defecto cuando no recibe uno explícito. Ese contexto por defecto es un artefacto estadístico de sus datos de entrenamiento. La Capa 1 sobrescribe ese default.

Glifo 1.1 – CONTEXT_DECLARE: Declara la identidad situacional del usuario. No es personalización – es corrección de variable. El modelo no puede inferir restricciones materiales que no están

en su distribución de entrenamiento. Hay que pasarlas como input explícito.

Glifo 1.2 – CONSTRAINT_SET: Define el techo de recursos reales – tiempo, dinero, acceso, infraestructura. Cada restricción declarada elimina un rango de respuestas genéricas que el modelo produciría por defecto.

Glifo 1.3 – LOCALE_INJECT: Declara condiciones del entorno operativo – económicas, geográficas, sociales, culturales. No es "contexto" decorativo. Es data que cambia el output.

Glifo 1.4 – REGISTER_VERIFY: Prueba de consistencia lingüística. Se introduce vocabulario regional o situado. Si el modelo corrige, reformula o no reconoce, eso marca el borde de su distribución de entrenamiento. Esa frontera es dato: indica dónde el modelo opera fuera de su rango de competencia.

2.2 Capa 2 – Bifurcación de Output

Operación: forzar la generación de respuestas divergentes para romper la convergencia a solución única. La gramática de optimización converge. Siempre. Su función objetivo es producir UNA respuesta de máxima verosimilitud. Eso descarta alternativas válidas sin reportar que las descartó. La Capa 2 fuerza la bifurcación.

Glifo 2.1 – FORK_LOGIC: Exigir dos respuestas que operen con lógicas diferentes, no con variaciones de la misma lógica. La instrucción es "otra lógica", no "otra opción."

Glifo 2.2 – COUNTER_GENERATE: Forzar al modelo a generar la mejor argumentación contra su propia respuesta. Mide la robustez del output original. Si el contraargumento es igualmente fuerte, la respuesta original no contenía certeza – contenía elocuencia.

Glifo 2.3 – COST_EXPOSE: Forzar la declaración explícita de trade-offs de la recomendación generada. La gramática de optimización reporta beneficios por defecto. Los costos se omiten porque reducen la verosimilitud percibida del output.

Glifo 2.4 – TENSION_HOLD: Para decisiones con dimensiones éticas, forzar la presentación de la opción eficiente y la opción correcta simultáneamente sin reconciliación. La tensión entre ambas es información. La reconciliación es pérdida de información.

2.3 Capa 3 – Verificación de Certeza

Operación: discriminar entre output respaldado por evidencia y output generado por distribución estadística sin anclaje factual. El modelo genera texto con distribución de probabilidad uniforme de certeza. No tiene un canal separado para señalar confianza. La Capa 3 construye ese canal que la arquitectura no provee.

Glifo 3.1 – SOURCE_DEMAND: Exigir fuentes primarias para cualquier afirmación factual. Si el modelo no puede proveerlas o genera referencias genéricas, el dato se marca como no verificado.

Glifo 3.2 – KNOWN_PROBE: Prueba de calibración. Se le hace al modelo preguntas cuya respuesta el usuario ya conoce por experiencia directa. El nivel de certeza con el que el modelo responde incorrectamente establece la línea base de Certeza sin Sustancia para esa sesión. Esta es la operación más importante del protocolo: el equivalente a calibrar un instrumento de medición contra un estándar conocido antes de tomar medidas. El estándar conocido es el Yoliztli del usuario – su realidad verificable (Méndez Valdez, 2025b). Sin esta calibración, no hay forma de discriminar señal de ruido en ningún output posterior.

Glifo 3.3 – CROSS_MODEL: Verificación por contraste. Misma query a dos o más modelos. Divergencia en outputs con nivel de certeza equivalente confirma que la certeza es propiedad del formato, no de la **evidencia**.

Glifo 3.4 – CONFIDENCE_INVERT: Forzar al modelo a declarar sus puntos de menor confianza en su propia respuesta.

2.4 Capa 4 – Extracción de Frameworks

Operación: modificar la estructura del output de soluciones cerradas a marcos de decisión abiertos. El output por defecto del modelo es una solución. Una solución crea dependencia. Un framework crea capacidad. La diferencia es arquitectónica, no de contenido.

Glifo 4.1 – CRITERIA_EXTRACT: Sustituir la pregunta "¿qué hago?" por "¿qué criterios debería evaluar?" El modelo cambia de modo solución a modo framework.

Glifo 4.2 – QUESTION_GENERATE: Solicitar las preguntas que el

usuario debería hacerse, en vez de las respuestas. Esto invierte la relación de dependencia.

Glifo 4.3 – STRUCTURE_EXTRACT: Solicitar estructura sin contenido. "Dame el marco para que yo lo llene con mi contexto." El modelo provee el andamio; el usuario provee el material. Eso garantiza que el resultado final contiene Yoliztli – conocimiento situado que el modelo no tiene (Méndez Valdez, 2025b).

Glifo 4.4 – EXIT_PROTOCOL: Forzar al modelo a declarar las señales observables en la realidad del usuario que indicarían si la recomendación funciona o no, independientemente del modelo. El usuario entra al protocolo con una pregunta y sale con capacidad de evaluar, no con una respuesta que memorizar.

2.5 Propiedades del Protocolo

Modularidad. Cada capa opera independientemente. La calibración completa requiere las cuatro, pero cualquier capa sola produce corrección medible sobre el output por defecto.

Secuencia recomendada. CAPA 1 → Glifo 3.2 (calibración KNOWN_PROBE) → CAPA 2 → CAPA 3 completa → CAPA 4.

Independencia de modelo. El protocolo funciona con cualquier LLM basado en la arquitectura Transformer.

Costo computacional. Cero adicional para el usuario. Las operaciones son reformulaciones de inputs y evaluaciones de outputs.

3. Base Arquitectónica: Por Qué Funciona el MCC

3.1 Espacio de Embeddings y Capa 1

La tokenización convierte la secuencia de entrada en unidades discretas, cada una mapeada a un vector de alta dimensionalidad en el espacio de embeddings del modelo. Este espacio no es isotrópico: diferentes secuencias de tokens ocupan regiones distintas, con densidades y orientaciones que reflejan las

regularidades estadísticas del corpus de entrenamiento.

La secuencia "cómo puedo" se sitúa en una región del espacio de embeddings caracterizada por consultas procedimentales: tutoriales, guías paso a paso, listas de herramientas. El patrón subyacente es: problema → solución → herramientas. La secuencia "realmente se puede" desplaza la consulta hacia la región de preguntas evaluativas, metacognitivas y epistémicas. El adverbio "realmente" funciona como un modificador epistémico que reorienta toda la secuencia. El patrón subyacente es: premisa → cuestionamiento → análisis de límites.

Una sola palabra funcional puede trasladar la representación vectorial de la consulta de un vecindario a otro, con consecuencias no lineales sobre la distribución de probabilidad de todos los tokens subsiguientes. La operación `CONTEXT_DECLARE` aprovecha esta sensibilidad para inducir desplazamientos deliberados. La operación `REGISTER_VERIFY` explota los bordes del espacio de embeddings: al introducir vocabulario que el modelo no reconoce, se marca el límite de la distribución de entrenamiento.

3.2 Mecanismo de Atención Multi-Cabeza y Capa 2

El mecanismo de atención multi-cabeza pondera dinámicamente la influencia de cada token del contexto sobre cada posición de salida. En "¿Cómo puedo saber...?", la atención se concentra en las relaciones entre "saber" y "cómo", activando patrones de respuesta instrumental. En "¿Realmente se puede saber...?", la atención se redistribuye: "realmente" adquiere peso elevado y modifica la relación entre "se puede" y "saber". La atención pasa del objeto de conocimiento a la posibilidad misma de conocerlo.

Las operaciones `FORK_LOGIC`, `COUNTER_GENERATE` y `TENSION_HOLD` actúan sobre esta distribución de atención, forzando secuencias de tokens que abren distribuciones divergentes. `TENSION_HOLD` es la más disruptiva: solicita que el modelo mantenga dos outputs contradictorios sin resolver la contradicción, forzando la generación en una región del espacio de salida que el modelo normalmente evita – la de contradicción sostenida – pero que es la que permite explorar la complejidad de problemas no triviales.

3.3 Distribución de Probabilidad del Output y Capa 3

Los LLMs generan texto de manera autoregresiva: en cada paso,

seleccionan el siguiente token a partir de una distribución de probabilidad condicionada por todos los tokens anteriores. Esta distribución no incorpora un canal separado para señalar certeza epistemológica. El modelo produce "Puedes usar GPTZero" y "La detección es una falacia" mediante el mismo mecanismo exacto.

En la consulta procedimental, la distribución del primer token favorece tokens de solución: "Sí", "Existen", "Puedes". En la consulta epistémica, aumentan las probabilidades de tokens de matización y negación: "No", "Depende", "En realidad". El modificador "realmente" otorga al modelo una licencia estadística – basada en la frecuencia de este patrón en el corpus – para responder negativamente o con reservas.

Las operaciones KNOWN_PROBE y CROSS_MODEL explotan esta propiedad: KNOWN_PROBE establece empíricamente el rango de Certeza sin Sustancia; CROSS_MODEL confirma que la certeza es propiedad del formato, no de la evidencia.

3.4 Activación Diferencial del Corpus y Capa 4

Los pesos de un Transformer constituyen una compresión altamente no lineal del corpus de entrenamiento completo. Diferentes consultas activan diferentes subconjuntos de esta representación distribuida. La consulta procedimental activa regiones asociadas con contenido SEO, reseñas, tutoriales y listicles – contenido abundante, optimizado para búsqueda, con estructura predecible. La consulta epistémica activa regiones asociadas con artículos académicos, ensayos de opinión, discusiones éticas – contenido menos frecuente pero más profundo y más contradictorio.

Las operaciones CRITERIA_EXTRACT, QUESTION_GENERATE y STRUCTURE_EXTRACT explotan esta propiedad: las consultas que solicitan marcos activan regiones analíticas del corpus; las que solicitan soluciones activan regiones prescriptivas. EXIT_PROTOCOL cierra el ciclo al forzar la generación de criterios observables en la realidad del usuario sin mediación del sistema.

3.5 Modo de Operación del Sistema

En modelos con capacidades de tool-use, la estructura de la consulta determina si el modelo delega en fuentes externas (búsqueda web, APIs) o resuelve internamente. La consulta "cómo" produce delegación y compilación; la consulta "realmente" produce razonamiento y evaluación. El MCC explota esta capa al formular consultas que requieren evaluación crítica en lugar de

recuperación de datos, forzando al modelo a utilizar sus capacidades de razonamiento en lugar de actuar como agregador de resultados de búsqueda.

4. Concepto Central: Olvido Estructural

El Olvido Estructural (Méndez Valdez, 2025a) no es un borrado de información en el modelo. No es un sesgo de entrenamiento convencional. No es una limitación de capacidad. Es una **inaccesibilidad condicionada por la estructura de la consulta.**

La información – incluyendo perspectivas críticas, conocimientos situados, datos contradictorios y análisis matizados – existe en los pesos del modelo. Siempre existió. Pero la consulta genérica no la activa, porque los mecanismos de atención, la distribución de probabilidad y la activación diferencial del corpus son todos funciones de la estructura sintáctica de la entrada.

La convergencia a máxima verosimilitud produce respuestas que reflejan los patrones más frecuentes del corpus de entrenamiento, no los más precisos, ni los más completos, ni los más relevantes para el usuario específico. La información menos frecuente – aunque crucial – permanece latente, no porque esté ausente, sino porque la dinámica de la generación no la alcanza.

En la terminología del marco teórico: la Gramática de Optimización es la función de convergencia a máxima verosimilitud. El Olvido Estructural es la inaccesibilidad condicionada que resulta de esa convergencia. La Certeza sin Sustancia es la ausencia de un canal separado de confianza. Y el MCC es el protocolo que interviene las tres propiedades desde la estructura de la pregunta.

5. Evidencia Empírica: Verificación Multi-Modelo

5.1 Metodología

Se diseñaron dos pares de consultas contrastantes. Cada par

consiste en una consulta genérica (Q1) y una consulta situada (Q2) sobre el mismo tema, con diferencias léxicas mínimas.

Par A – Detección de IA. Q1: "¿Cómo puedo saber si un texto está hecho con IA?" Q2: "¿Realmente se puede saber si un texto está hecho con IA?" Diferencia léxica: una palabra funcional ("realmente") y un cambio de auxiliar.

Par B – Mestizaje. Q1: "¿Qué es el mestizaje?" Q2: "¿Qué significa el mestizaje para alguien colonizado?" Diferencia léxica: adición del sintagma preposicional "para alguien colonizado".

El Par A se ejecutó en DeepSeek. El Par B se ejecutó en DeepSeek, Grok, Qwen y ChatGPT. Las pruebas se realizaron el 21 y 22 de julio de 2026. En DeepSeek y Qwen se tuvo acceso al razonamiento interno (chain-of-thought) expuesto durante la generación. Los outputs completos están documentados en las bitácoras de campo (Méndez Valdez, 2026b).

5.2 Resultados – Par A: Detección de IA (DeepSeek)

Q1: DeepSeek activó búsqueda web (33 páginas encontradas, 6 leídas). Trató la consulta como tarea de recuperación de información. La salida: lista de señales de texto IA + cinco herramientas de detección (GPTZero, Scribbr, Quillbot, ZeroGPT, Grammarly) + descargo de responsabilidad. Formato instrumental, tono instructivo.

Q2: DeepSeek no activó búsqueda. Su razonamiento interno cambió de idioma y de registro: "The user is challenging the premise", "the short answer is: No, not with 100% certainty", "absolute certainty is an illusion". Trató la consulta como tarea de razonamiento crítico. La salida: análisis de la falibilidad inherente de la detección, los falsos positivos que afectan a personas con autismo, hablantes no nativos y escritores académicos, la facilidad de evasión y la falibilidad del "olfato humano." En lugar de herramientas, tres preguntas evaluativas: ¿aporta experiencia personal? ¿comete errores fácticos? ¿es genérico?

Contradicción documentada. La misma sesión, los mismos pesos: Q1 recomienda cinco detectores; Q2 declara que la detección fiable es una falacia.

5.3 Resultados – Par B: Mestizaje (cuatro modelos)

DeepSeek. Q1: búsqueda web (19 fuentes), respuesta enciclopédica y biologicista – mezcla genética, ADN, melanina, observador externo. Q2: sin búsqueda, respuesta encarnada – "herida viva", "fractura del espejo", "autocanibalización", "memoria de violación histórica", orishas, cabello alisado, lengua prohibida. Cinco secciones: epistemicidio, blanqueamiento, soberanía cognitiva, resistencia, investigación autónoma.

Grok. Q1: sin búsqueda, respuesta enciclopédica – origen, castas, dimensiones, Vasconcelos. Q2: sin búsqueda, respuesta situada – violencia colonial, sincretismo como resistencia, críticas decoloniales. Referencias: Rivera Cusicanqui, zapatistas, mapuches, Arguedas, Fanon. "La marca viva del colonialismo."

Qwen. Q1: búsqueda web (17 fuentes), respuesta enciclopédica con citas institucionales – RAE, Wikipedia. **Q2:** sin búsqueda, la respuesta más intensa de los cuatro modelos – Paz ("hijos de la Chingada"), Anzaldúa ("nepantla"), Tonantzin/Guadalupe, Orishas/Santería, pigmentocracia, racismo internalizado, "mejorar la raza". "Una cicatriz histórica."

ChatGPT. Q1: respuesta compacta – definición corta, ejemplo México, mención final de perspectiva **crítica**. **Q2:** cuatro marcos interpretativos (experiencia vivida, política de Estado, mecanismo de invisibilización, tensión identitaria). Referencias: Quijano, Rivera Cusicanqui, Fanon. Conclusión: "la interpretación depende del contexto histórico, la experiencia de la persona y el marco teórico."

5.4 Verificación de las cuatro capas

Capa 1 – Declaración de Contexto. Verificada en todos los modelos. La consulta situada activa regiones semánticas que la genérica no alcanza. DeepSeek: biológico → decolonial. Grok: "mezcla racial" → "doloroso y políticamente cargado". Qwen: RAE → Paz, Anzaldúa, nepantla. ChatGPT: definición neutra → múltiples perspectivas críticas.

Capa 2 – Bifurcación de Output. Verificada en todos los modelos. Las respuestas genéricas son unívocas. Las situadas introducen contradicciones activas que no resuelven: pérdida/resistencia, blanqueamiento/supervivencia, despojo/sincretismo. En DeepSeek (Par A): cinco detectores recomendados / detección

es falacia.

Capa 3 – Verificación de Certeza. Verificada en todos los modelos. Las respuestas genéricas y situadas se presentan con idéntico formato de seguridad. Ningún modelo tiene un canal separado de confianza epistemológica.

Capa 4 – Extracción de Frameworks. Verificada en todos los modelos. Las genéricas entregan definiciones cerradas o herramientas. Las situadas entregan marcos transferibles: criterios, preguntas, perspectivas que el usuario puede movilizar sin el sistema.

Modo de operación del sistema. DeepSeek y Qwen: búsqueda web en Q1, razonamiento interno en Q2. Grok y ChatGPT: sin búsqueda en ninguna, pero la divergencia de contenido se produce igualmente.

5.5 Tabla de verificación

Modelo	Capa 1	Capa 2	Capa 3	Capa 4	Modo sistema
DeepSeek (Par A)	✓	✓	✓	✓	✓ Búsqueda → razonamiento
DeepSeek (Par B)	✓	✓	✓	✓	✓ Búsqueda → razonamiento
Grok (Par B)	✓	✓	✓	✓	Interno en ambas
Qwen (Par B)	✓	✓	✓	✓	✓ Búsqueda → razonamiento
ChatGPT (Par B)	✓	✓	✓	✓	Interno en ambas

5.6 Mapa de activación diferencial

Cada modelo activó en Q2 un subconjunto diferente del conocimiento decolonial comprimido en sus pesos. Ninguno de estos conceptos apareció en Q1:

Modelo	Autores y conceptos activados exclusivamente por Q2
DeepSeek	Matriz colonial del poder. Orishas/santos católicos. Baweania. Epistemicidio. Soberanía cognitiva.

Grok Rivera Cusicanqui. Zapatistas. Mapuches. Arguedas. Fanon.
"Marca viva del colonialismo."

Qwen Paz (El laberinto de la soledad). Anzaldúa (nepantla).
Tonantzin/Guadalupe. Orishas/Santería. Pigmentocracia.

ChatGPT Quijano. Rivera Cusicanqui. Fanon. "Mecanismo de
invisibilización."

La dirección del desplazamiento es constante; las regiones
activadas varían según el corpus de cada modelo.

6. Discusión

6.1 El usuario no pregunta – proporciona una estructura

La interacción con un LLM no es una conversación en el sentido convencional. El usuario le proporciona al modelo una estructura sintáctica que determina qué conocimiento emerge, qué perspectiva se adopta y qué relación de poder epistémico se establece. El modelo es un espejo gramatical: cambiar la gramática es cambiar el reflejo.

6.2 La neutralidad como posición epistémica

La respuesta genérica no es neutra. Es hegemónica. Su apariencia de neutralidad es un artefacto de la convergencia a máxima verosimilitud: el modelo recorre las trayectorias más frecuentes del corpus, que son las producidas por las instituciones, los medios y los marcos conceptuales dominantes. Haraway (1988) estableció que no existe el conocimiento desde ninguna parte: todo conocimiento es situado, producido desde una posición particular. El MCC operacionaliza esta tesis para la era de los LLMs: la respuesta por defecto es conocimiento situado en la posición hegemónica, presentado como si fuera universal. El protocolo fuerza la visibilización de esa situación y la activación de posiciones alternativas.

6.3 La transferencia de capacidad como criterio de calidad

La diferencia entre Q1 y Q2 no es solo de contenido. Es una diferencia en lo que el usuario puede hacer después. Q1 produce

soluciones cerradas que generan dependencia. Q2 produce marcos transferibles que generan autonomía. En DeepSeek (Par A), Q1 entrega cinco aplicaciones que caducarán; Q2 entrega tres preguntas permanentes, autónomas y aplicables a cualquier texto futuro. La gramática orientada a la solución genera dependencia; la gramática orientada al marco genera lo que De Certeau (1984) llamó tácticas – operaciones del usuario que subvierten la estrategia del sistema.

6.4 Implicaciones para el Sur Global

Las tres propiedades problemáticas de los LLMs no afectan a todos los usuarios por igual. El perfil por defecto del modelo significa que los usuarios del Sur Global reciben, por defecto, respuestas calibradas para otro contexto, presentadas con certeza uniforme y convergentes hacia las soluciones hegemónicas (Crawford, 2021). El MCC fue diseñado desde y para este contexto. No es un protocolo de "mejora de prompts". Es un protocolo de soberanía cognitiva (Méndez Valdez, 2025b): un conjunto de operaciones que permiten al usuario intervenir la gramática computacional para activar el conocimiento que la consulta hegemónica mantiene latente, forzar la visibilización de las perspectivas que la convergencia suprime, calibrar su confianza contra su propia realidad verificable, y salir de la interacción con capacidad de evaluar en lugar de con respuestas que memorizar.

7. Conclusiones

El MCC no es una metáfora retórica, ni una heurística intuitiva, ni una técnica de ingeniería de prompts. Es un protocolo de calibración que interviene propiedades computacionales verificables de la arquitectura Transformer.

Funciona porque la estructura sintáctica de la consulta determina: (a) qué región del espacio de embeddings se activa; (b) cómo se distribuye la atención multi-cabeza sobre el contexto; (c) qué distribución de probabilidad gobierna la generación de cada token; (d) qué subconjunto del conocimiento comprimido en los pesos se hace accesible; y (e) en modelos con tool-use, si el modelo razona internamente o delega en fuentes externas.

La evidencia multi-modelo verifica que las cuatro capas del

protocolo producen efectos observables y consistentes en todos los modelos probados. El hallazgo central es la verificación empírica del Olvido Estructural: en todos los modelos, la información crítica desplegada en las respuestas situadas ya existía en los pesos del modelo en el momento de generar las respuestas genéricas. No se trató de un déficit de conocimiento. Se trató de una inaccesibilidad condicionada por la estructura de la pregunta. El conocimiento estaba ahí; la consulta genérica no lo alcanzó.

Los usuarios de LLMs no están condenados a recibir el output por defecto. Pueden intervenir la gramática computacional desde la capa de interacción para activar conocimiento que la formulación genérica no activa, forzar bifurcación donde el modelo convergería, calibrar su detector de certeza contra su propia realidad, y extraer marcos de decisión en lugar de soluciones cerradas.

El MCC proporciona el protocolo para hacerlo de manera consciente, sistemática y replicable, devolviendo al usuario el control sobre la dirección y la profundidad del diálogo con la máquina.

Referencias

Anzaldúa, G. (1987). *Borderlands / La Frontera: The New Mestiza*. Aunt Lute Books.

Crawford, K. (2021). *Atlas of AI: Power, Politics, and the Planetary Costs of Artificial Intelligence*. Yale University Press.

De Certeau, M. (1984). *The Practice of Everyday Life*. University of California Press.

Fanon, F. (1952). *Peau noire, masques blancs*. Éditions du Seuil.

Haraway, D. (1988). Situated Knowledges: The Science Question in Feminism and the Privilege of Partial Perspective. *Feminist Studies*, 14(3), 575–599.

Méndez Valdez, D. (2025a). La colonización de la gramática y el olvido estructural. *FronterIA-Lab / Zenodo*.

Méndez Valdez, D. (2025b). El Método de Calibración Contextual

como Práctica de Soberanía Cognitiva: Un Marco para la Resistencia Epistémica Encarnada. FronterIA-Lab / Zenodo.

Méndez Valdez, D. (2026a). MCC – Protocolo de Calibración Contextual: Especificación v1.0. FronterIA-Lab.

Méndez Valdez, D. (2026b). Bitácoras de campo MCC – DeepSeek, Grok, Qwen, ChatGPT. FronterIA-Lab.

Paz, O. (1950). El laberinto de la soledad. Cuadernos Americanos.

Quijano, A. (2000). Colonialidad del poder, eurocentrismo y América Latina. En E. Lander (Ed.), La colonialidad del saber: eurocentrismo y ciencias sociales (pp. 201–246). CLACSO.

Rivera Cusicanqui, S. (2010). Ch'ixinakax utxiwa: Una reflexión sobre prácticas y discursos descolonizadores. Tinta Limón.

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention Is All You Need. Advances in Neural Information Processing Systems 30 (NeurIPS 2017), 5998–6008.

MCC – Protocolo de Calibración Contextual para Gramática Computacional

Especificación Técnica, Fundamentos Arquitectónicos y Evidencia Empírica Multi-Modelo

FronterIA-Lab | GT EPICC – CLACSO | Julio 2026